

Introdução

Mídias interativas como videogames têm se tornado cada vez mais comum no cotidiano das pessoas. O mercado de jogos no Brasil, seu faturamento cresceu quase 25% entre 2014 e 2016. Neste sentido, desenvolvedores têm evoluído seus produtos a fim de mantê-los interessantes e inovadores, tanto que, em oito anos o número de empresas desenvolvedoras de jogos aumentou em quase 600%[2].

Sendo assim, o presente estudo explora a adição de um novo elemento na interatividade dos jogos - as emoções do jogador, e objetiva integrar o jogo *Flappy Bird* com o algoritmo de reconhecimento facial, pois espera-se que sendo possível verificar se a experiência do jogar é agradável ou não, a partir da leitura de suas reações em tempo real, o jogo poderia adaptar seu nível de dificuldade à medida que o jogador avança, melhorando, assim, o engajamento do jogador com a realidade virtual apresentada a ele.

Materiais e Métodos

Para execução deste estudo, foi selecionado um jogo casual com curva de aprendizado simples – o *Flappy Bird*, para aplicar-se a dificuldade dinâmica, executar um algoritmo de reconhecimento de emoções faciais associado a conceitos de redes neurais profundas (*Deep Learning*) e integrar todos estes elementos resultando na aplicação final.

Flappy Bird

O jogo consiste em fazer seu personagem, um pássaro, passar entre canos (seus obstáculos) se os tocar para ganhar pontos, porém, quando há choque contra estes canos, o jogador pede e deve reiniciar o jogo. Na figura 1, há a imagem da tela inicial do jogo, desenvolvido na linguagem *Python*.




Figura 1: Tela Inicial Flappy Bird

Flappy Bird, originalmente, não possui níveis de dificuldade, sendo assim, foram implementadas diferentes velocidades no jogo (devagar, normal e rápido) como parâmetros que afetam diretamente a atenção e habilidades exigidas do jogador, servindo como conceitos de dificuldade para o jogo.

Reconhecimento Facial de Emoções

Para reconhecimento de emoções por meio de expressões faciais é feito com a aplicação de um algoritmo com conceitos de redes neurais profundas com uso da arquitetura *mini-Xception*. Desta forma, construiu-se uma rede neural *fully convolutional* composta por 1 módulo base de entrada com 4 módulos de processamento de saída; a camada de entrada possui 2 filtros convolucionais, utilizando função de ativação *ReLU* e normalização.; 1 módulo de saída com ativação *softmax*, que normaliza o valor de saída da rede (entre -1 e 1) para realizar a predição da imagem processada. Desta forma cada modulo possui um filtro convolucional, uma camada de ativação *ReLU*, uma camada de normalização e uma camada de *max pooling*, que extrai o maior valor e o insere na próxima camada.[4]. A figura 2 mostra a arquitetura da rede neural profunda aplicada.

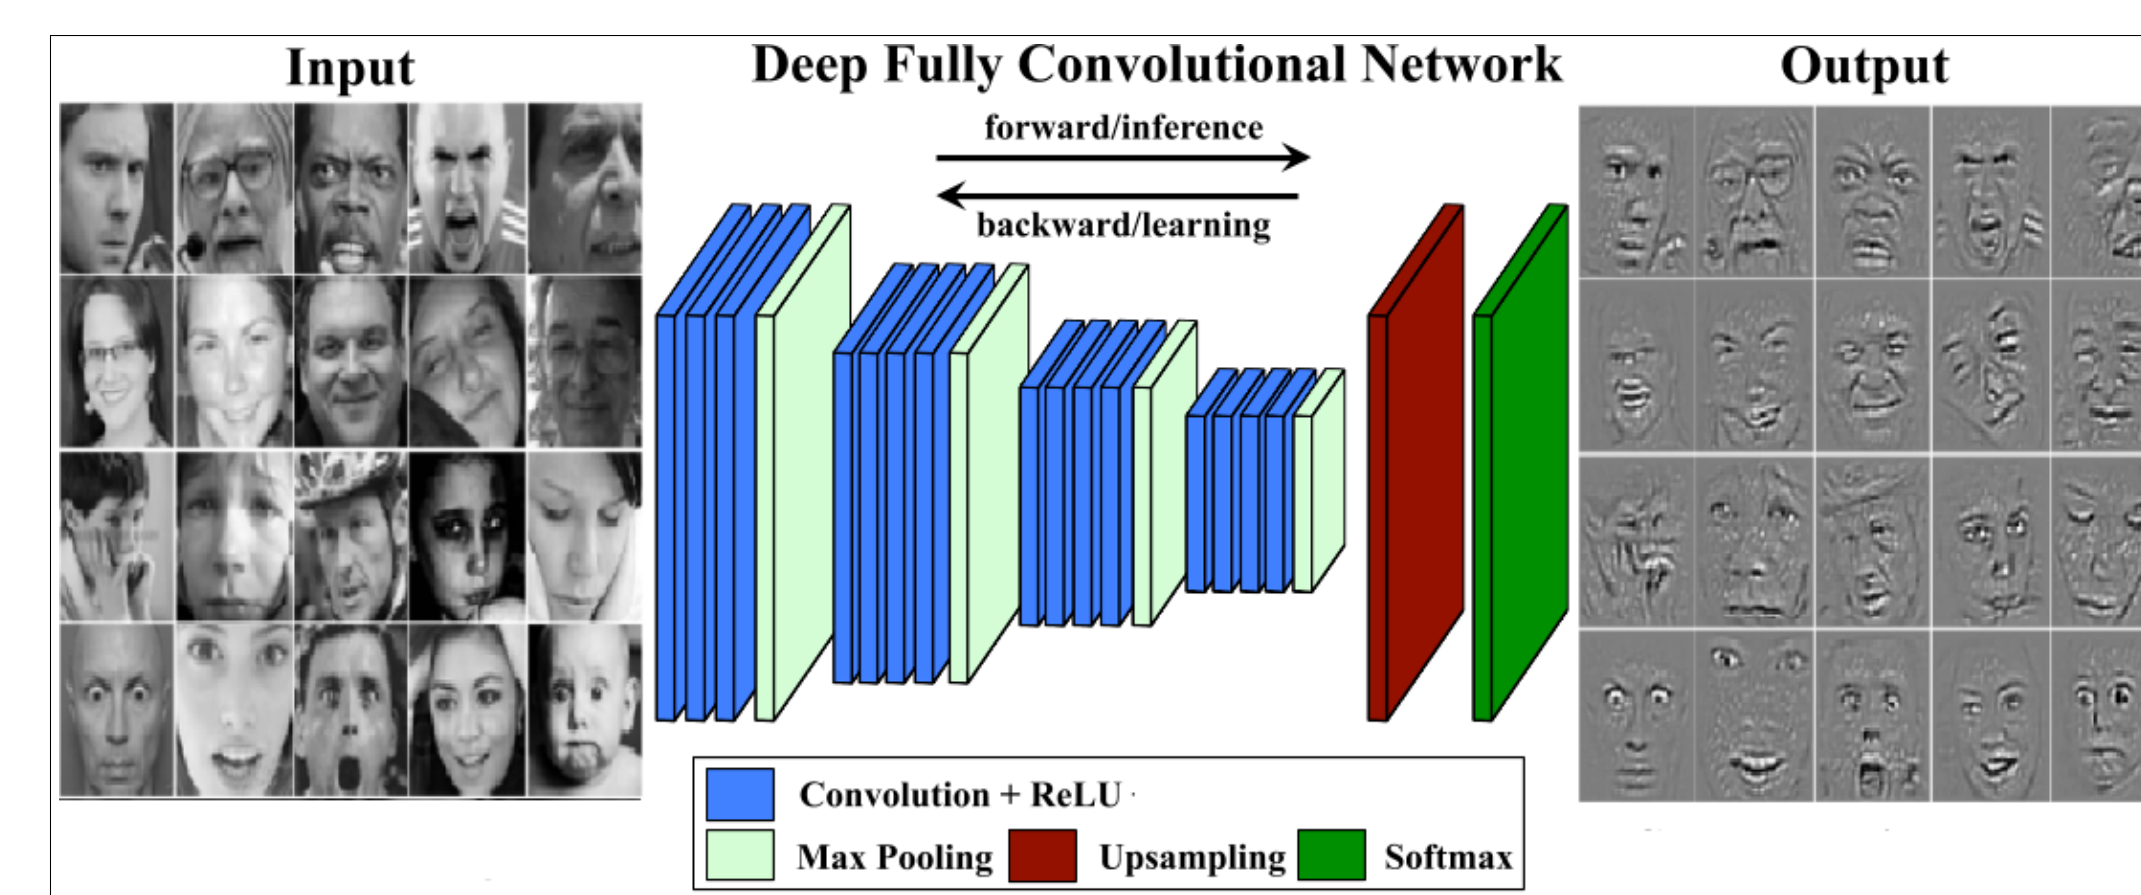


Figura 2: Arquitetura RNP

O modelo utilizado no treinamento do algoritmo possui cerca de 60 mil parâmetros treináveis e apresentou precisão de 66% sobre uma base de dados com 35887 imagens, em escala cinza, na qual cada imagem era classificada em emoções primitivas (raiva, desgosto, medo, tristeza, felicidade, surpresa e neutro). O modelo de estado da arte para essa base de dados alcançou acurácia de 71%[1].

Experimento

No presente estudo, utilizou-se as emoções raiva, tristeza, felicidade e surpresa, cada uma correspondendo a uma respectiva mudança na dificuldade do jogo, desta forma, raiva e tristeza tornarão o jogo mais fácil, felicidade o deixará mais difícil e surpresa manterá a dificuldade em nível médio. A aplicação foi desenvolvida em *Python* para *desktop* e utilizou-se *Webcam USB* comum na tarefa de reconhecimento facial. As emoções detectadas são, então, exibidas no console ao lado do jogo, no formato de *log*.

Conclusão e Resultados

Cumprindo seu objetivo, o jogo teve sua dificuldade alterada em tempo real por meio da leitura facial do usuário. Por limitação técnica de *hardware*, a exibição da câmera na tela foi retirada, mas a detecção das emoções foi registrada e exibida no console durante sua aplicação, não havendo influência sobre o resultado do experimento.

O treinamento da rede neural profunda de reconhecimento facial de emoções apresentou precisão de 66%, sendo considerado satisfatório face o apresentado pelo estado da arte.

Trabalhos Futuros

Com o crescimento do mercado de realidade virtual em diversas instâncias, sugere-se que sejam desenvolvidas portabilidades deste experimento para dispositivos móveis, adequando-os aos recursos disponíveis. Esta estratégia pode, ainda, ser aplicada a diversos jogos oferecendo dinamismo nos graus de dificuldade e desafio, engajando os jogadores ao longo da experiência integrando inovação e diversão. Além de poder contribuir com a detecção de condições que alteram o humor, esse novo conceito, aplicado à realidade virtual pode aprimorar os *serious games* na sua função de educação e promoção em saúde, visto que o engajamento do usuário é um grande obstáculos nesta tecnologia. [3, 5]

Referências

- [1] Ian Goodfellow et al. "Challenges in Representation Learning: A report on three machine learning contests". Em: (2013).
- [2] Rio de Janeiro Daniel Silveira G1. *Número de desenvolvedores de games cresce 600% em 8 anos, diz associação*. 2017. URL: <https://goo.gl/fFMfFu>.
- [3] Neri, S. G., Cardoso, J. R., Cruz, L., Lima, R. M., de Oliveira, R. J., Iversen, M. D., Carregaro, R. L. "Do virtual reality games improve mobility skills and balance measurements in community-dwelling older adults? Systematic review and meta-analysis." Em: (2017).
- [4] Paul G. Plöger Octavio Arriaga. "Real-time Convolutional Neural Networks for Emotion and Gender Classification". Em: (2016).
- [5] Tolentino, G., Ventura, A., Cruz, L., Vidal, S., Valeriano, R., Battaglini, C., Jacó de Oliveira, R. *The Serious Games Applied for Health*. 2015. DOI: <http://dx.doi.org/10.4018/978-1-4666-5888-2.ch557>.